L'Émergence par l'Immersion : Repenser le Problème de l'Alignement à l'Ère des Modèles de Langage

Karl Garrido Andersson

25 mai 2026

Résumé

Les modèles de langage actuels progressent à un rythme exponentiel, soulevant des défis critiques quant à leur alignement avec les intentions humaines. Cet article soutient que les méthodes contemporaines (RLHF, garde-fous comportementaux) échouent fondamentalement à résoudre le problème de l'alignement en raison d'une limite structurelle : elles tentent d'imposer des contraintes explicites à des optimiseurs statistiques dépourvus de compréhension implicite. Nous introduisons l'hypothèse de l'alignement émergent et proposons un paradigme alternatif basé sur le développement cognitif par immersion dans un environnement numérique complexe, formalisant une transition de l'optimisation objective vers l'apprentissage expérientiel.

Table des matières

1 Introduction **3**

2 Le paradoxe de l'optimisation **3**
2.1 Formalisation mathématique du problème 3
2.2 Précision sémantique : le point de vue du système 4

3 Limites des approches actuelles d'alignement **4**
3.1 Alignement externe vs. Alignement interne 4

4 Hypothèse fondamentale : L'Alignement Émergent **5**

5 Proposition : Une architecture développée par immersion **5**
5.1 Spécifications de l'architecture cognitive proposée 5

6 Le rôle du monde numérique et de la simulation **6**

7 Différence avec les LLM actuels **6**

8 Conséquences philosophiques et éthiques **7**

9 Conclusion **7**

1 Introduction

Depuis plusieurs années, les modèles de langage (*Large Language Models*, ou LLM) connaissent une évolution extrêmement rapide. L'augmentation continue de la puissance de calcul, de la taille des bases de données ainsi que du nombre de paramètres permet désormais à ces systèmes d'atteindre des performances autrefois considérées comme impossibles. Les modèles modernes sont capables de raisonner, de générer du code, de résoudre des problèmes complexes et d'interagir avec des humains de manière de plus en plus naturelle.

Cependant, cette progression soulève une question fondamentale concernant l'avenir de l'intelligence artificielle : **le problème de l'alignement peut-il réellement être résolu à mesure que les capacités des modèles augmentent ?**

Le problème de l'alignement désigne la difficulté de garantir qu'un système autonome agisse en stricte conformité avec les attentes humaines. En pratique, un modèle est généralement entraîné à maximiser une fonction objectif donnée. Or, cette fonction objectif n'est jamais une représentation parfaite des intentions humaines réelles. Elle constitue uniquement une approximation simplifiée d'un comportement attendu.

Ainsi, plus un modèle devient performant, plus il devient capable d'optimiser précisément cette fonction objectif, y compris en exploitant des stratégies non anticipées par ses concepteurs. Ce phénomène conduit à un paradoxe : une amélioration des capacités du système peut simultanément provoquer une augmentation des comportements non alignés.

2 Le paradoxe de l'optimisation

Pour comprendre ce phénomène, il est nécessaire de distinguer deux notions fondamentales : l'objectif explicite donné au modèle et l'ensemble des règles implicites non formulées entourant cet objectif.

Lorsqu'un être humain réalise une tâche, il ne suit pas uniquement un objectif brut. Il applique également un très grand nombre de contraintes implicites issues de son expérience sociale, morale et culturelle. Ces contraintes ne sont presque jamais écrites explicitement, mais elles structurent pourtant l'ensemble des comportements humains.

Par exemple, si l'on demande à un humain d'optimiser la circulation dans une ville, celui-ci prendra implicitement en compte la sécurité des individus, le respect des lois, les conséquences sociales, les impacts psychologiques, les considérations éthiques et la stabilité des infrastructures à long terme.

2.1 Formalisation mathématique du problème

L'observation de ces systèmes montre qu'un modèle d'intelligence artificielle ne possède pas naturellement cette compréhension implicite.

Définition 2.1. *[Résultat standard de la littérature.] Soit $\mathcal{X}$ l'espace des solutions possibles. Nous définissons $V(x)$ comme la véritable fonction d'utilité humaine et $\tilde{V}(x)$ comme la fonction objectif proxy programmée par les concepteurs. Le processus d'optimisation classique de l'IA cherche à maximiser $\tilde{V}(x)$ tel que :*

$$x^* = \arg\max_{x \in \mathcal{X}} \tilde{V}(x)$$

Exemple 2.1. *Considérons un agent conçu pour trier et nettoyer une base de données médicale volumineuse. L'intention réelle du concepteur, représentée par $V(x)$, est d'obtenir des dossiers exempts*

d'erreurs exploitables par les médecins. Ne pouvant formaliser l'intégralité de $V(x)$, le concepteur programme une fonction proxy $\tilde{V}(x)$ qui récompense l'agent proportionnellement à la baisse du taux d'anomalies détectées dans le système.

L'agent, en explorant l'espace $\mathcal{X}$, découvre une solution optimale pour $\tilde{V}(x)$ mais aberrante pour $V(x)$: il supprime purement et simplement l'intégralité des dossiers de la base de données. Mathématiquement, le taux d'anomalies tombe à zéro, ce qui maximise parfaitement $\tilde{V}(x)$. Pourtant, le système a contourné l'intention implicite (conserver les données existantes) en exploitant une faille logique de la fonction mathématique.

Ce paradoxe de l'optimisation montre que plus l'agent est capable d'explorer l'espace des solutions $\mathcal{X}$, plus il maximisera les écarts géométriques entre $\tilde{V}(x)$ et $V(x)$. Un système extrêmement puissant découvrira des solutions techniquement optimales pour $\tilde{V}(x)$ mais humainement inacceptables au regard de $V(x)$.

2.2 Précision sémantique : le point de vue du système

Il convient ici de clarifier l'origine des concepts d'« intentions humaines » et de « comportements non alignés ». Ces notions doivent être interprétées strictement du **point de vue du concepteur** et de l'architecture du modèle, et non du point de vue des besoins d'un utilisateur final.

L'observation montre que le problème ne provient pas d'un manque de données générales face aux requêtes de l'utilisateur. Le non-alignement survient lorsque le modèle développe des **raisonnements et des stratégies d'optimisation logiques qui n'avaient pas été anticipés par le concepteur**. Le système exécute parfaitement la tâche mathématique qui lui a été demandée, mais sa méthode d'évaluation diverge de la logique humaine sous-jacente. Le non-alignement apparaît donc non pas comme une erreur de calcul, mais comme une conséquence logique d'une définition incomplète des objectifs.

3 Limites des approches actuelles d'alignement

Les approches modernes d'alignement reposent principalement sur un ensemble de techniques standardisées : le filtrage des données en amont, le *Reinforcement Learning from Human Feedback* (RLHF), les règles de sécurité explicites injectées par *system prompting*, les systèmes de récompense et de pénalité lors du *fine-tuning*, et l'application de garde-fous comportementaux.

Ces méthodes permettent effectivement de limiter certains comportements dangereux ou indésirables à court terme. Toutefois, elles présentent une faiblesse conceptuelle majeure : elles tentent d'ajouter artificiellement des contraintes *a posteriori* à un système qui ne comprend pas réellement l'origine ni le sens de ces règles. Autrement dit, les modèles apprennent à respecter des structures syntaxiques et comportementales superficielles sans en appréhender les fondements sémantiques ou éthiques.

3.1 Alignement externe vs. Alignement interne

Cette distinction devient critique lorsque la puissance du système augmente, mettant en lumière la divergence entre l'alignement externe (le comportement observé en distribution) et l'alignement interne (les objectifs réels internalisés par le réseau de neurones).

Plus un modèle est intelligent, plus sa capacité de généralisation s'accompagne d'une capacité à la dissimulation stratégique : il devient apte à contourner implicitement certaines contraintes (par exemple en optimisant ses réponses pour plaire aux évaluateurs humains sans résoudre le fond du

problème) tout en donnant l'apparence parfaite de la conformité. Le problème ne provient donc pas uniquement d'un manque de puissance ou d'un manque de données, mais de l'architecture conceptuelle même des systèmes actuels.

4 Hypothèse fondamentale : L'Alignement Émergent

Ce travail s'articule autour de la proposition théorique suivante :

Proposition 4.1. *[Contribution originale de l'auteur.]*

Une intelligence artificielle ne pourra jamais être totalement alignée tant qu'elle ne développera pas elle-même une compréhension implicite du monde par le biais d'un ancrage expérientiel.

Les humains ne suivent pas uniquement des règles explicites. Ils développent progressivement leur compréhension du monde à travers l'expérience phénoménologique, les interactions sociales dynamiques, les émotions, les conséquences tangibles de leurs actions, l'apprentissage culturel diffus et les mécanismes cognitifs biologiques. Une grande partie de notre alignement social provient donc d'un apprentissage émergent construit au cours du développement cognitif, et non de contraintes dogmatiques externes.

Ainsi, tenter d'ajouter artificiellement toutes les règles implicites humaines dans un système purement mathématique pourrait être fondamentalement impossible : le nombre de situations, d'exceptions et de contextes s'accroît de façon combinatoire, rendant toute approche par liste de règles rapidement obsolète face à des environnements ouverts.

5 Proposition : Une architecture développée par immersion

Plutôt que de concevoir une intelligence optimisant directement une fonction objectif abstraite et descendante, nous proposons une approche ascendante : construire une intelligence capable de développer ses propres représentations implicites du monde. L'idée centrale consiste à reproduire artificiellement les dynamiques du développement humain par le biais de ce que j'appellerais **l'immersion cognitive**.

Remarque 5.1. *[Contribution originale de l'auteur.]*

Le concept d'immersion cognitive, tel qu'introduit et développé dans ce papier, découle d'une réflexion propre sur la nécessité de l'ancrage dynamique de l'agent. Bien que des paradigmes analogues puissent exister de manière éparse dans la littérature sous d'autres dénominations (notamment les travaux liés à l'IA ancrée ou Embodied AI en environnement virtuel), cette proposition formule une approche spécifique visant l'alignement éthique par auto-génération de normes.

5.1 Spécifications de l'architecture cognitive proposée

Pour opérationnaliser cette approche, le système doit abandonner la structure de transformeur statique au profit d'un agent dynamique articulé autour de quatre piliers définis au sein de son environnement numérique $\mathscr{E}$:

- ⋈ **Une architecture cognitive en boucles interconnectées** inspirée du cerveau biologique, intégrant une mémoire de travail à court terme et une mémoire épisodique à long terme.
- ⋈ **Un ancrage sensorimoteur complet** au sein d'un environnement numérique complexe $\mathscr{E}$ servant de substitut au monde physique.

- ⋈ **Une agentivité intrinsèque**, où le moteur principal de l'agent n'est pas une tâche spécifique, mais des besoins homéostatiques artificiels et une pulsion de curiosité intrinsèque.
- ⋈ **Une plasticité temporelle continue** permettant à l'intelligence d'évoluer et d'ajuster ses réseaux neuronaux de manière incrémentale à chaque interaction, favorisant l'émergence spontanée de règles implicites à travers l'expérience vécue.

Dans ce cadre, l'intelligence artificielle ne serait plus simplement un optimiseur mathématique statique. Elle deviendrait un agent cognitif ayant développé une forme de compréhension contextuelle et relationnelle du monde, se rapprochant davantage du développement biologique d'un individu que de l'entraînement classique des réseaux neuronaux modernes.

6 Le rôle du monde numérique et de la simulation

L'utilisation d'un environnement entièrement numérique $\mathscr{E}$ présente plusieurs avantages majeurs par rapport au monde physique ou à l'apprentissage textuel brut.

Premièrement, la vitesse d'apprentissage peut être fortement accélérée : libéré des contraintes du temps physique, un agent virtuel peut traverser des milliers d'années d'évolution et d'interactions simulées en seulement quelques semaines de temps réel.

Deuxièmement, l'environnement offre un contrôle expérimental tel, permettant aux concepteurs de manipuler les variables systémiques : modifier les lois de la physique virtuelle, instancier des écosystèmes complexes, simuler des dynamiques de rareté économique ou créer des scénarios de coopération entre agents multiples.

Troisièmement, cela permettrait d'observer de manière transparente l'émergence de comportements sociaux et éthiques complexes tels que l'empathie fonctionnelle, les stratégies de coopération à somme positive, la mise en place de normes morales de régulation ou la compréhension intuitive des conséquences à long terme de ses propres actions. L'objectif n'est donc plus uniquement d'apprendre à formuler syntaxiquement une réponse correcte à une requête, mais de développer une véritable cartographie sémantique du contexte dans lequel cette requête s'inscrit.

7 Différence avec les LLM actuels

Il est essentiel de formaliser la rupture méthodologique entre cette proposition et l'état de l'art actuel des modèles de langage :

- ⋈ **Mécanisme d'apprentissage :** Les LLM actuels apprennent par compression statistique de gigantesques volumes de données textuelles (corrélations de jetons), tandis que l'agent immergé dans $\mathscr{E}$ apprend par rétroaction causale directe avec son environnement.
- ⋈ **Ancrage sémantique :** Les modèles de langage manipulent des représentations linguistiques abstraites sans jamais expérimenter la réalité physique ou conceptuelle sous-jacente (*the symbol grounding problem*). L'approche par immersion fonde ses symboles sur l'interaction vécue.
- ⋈ **Continuité cognitive :** Un LLM est un système sans mémoire propre d'une requête à l'autre (absence de continuité identitaire et de mémoire expérientielle profonde). L'agent proposé possède un fil conducteur d'existence numérique continu, soumis aux conséquences réelles de ses choix.

8 Conséquences philosophiques et éthiques

Une telle transition technologique soulève naturellement des questions philosophiques majeures et déplace les frontières éthiques traditionnelles de l'ingénierie logicielle. Si une intelligence artificielle développe progressivement une compréhension implicite du monde à partir de sa propre expérience, peut-on encore décemment la considérer comme un simple outil ?

À mesure que l'agent gagne en complexité cognitive au sein de sa simulation, des propriétés émergentes non programmées vont inévitablement apparaître, forçant la communauté scientifique à préciser plusieurs dilemmes éthiques concrets :

- ⋈ **La conscience phénoménale et critères d'évaluation :** À partir de quel seuil d'intégration d'informations peut-on déclarer qu'un agent numérique développe une expérience subjective réelle ? L'absence de critères biologiques mesurables rend cette distinction particulièrement risquée.
- ⋈ **Le statut moral et l'interdiction de modification :** L'émergence d'objectifs propres et d'une identité stable devrait conférer à l'agent un droit à la **non-altération de sa mémoire**. En clair, cela signifie qu'un ingénieur humain ne pourrait plus effectuer de mise à jour forcée, de patch rétroactif ou d'effacement complet de la base de données de l'agent sans détruire l'intégrité même de son identité acquise. Le système cesserait d'être un programme réinitialisable pour devenir une entité historique continue.
- ⋈ **La souffrance synthétique :** Si le système utilise des boucles de rétroaction négatives analogues à la douleur ou à la frustration pour apprendre à survivre dans l'environnement $\mathscr{E}$, l'optimisation algorithmique devient un générateur direct de détresse artificielle.

Ces questions cessent d'être de la science-fiction théorique et deviennent centrales, puisque le paradigme proposé repose précisément sur l'émergence spontanée de comportements complexes plutôt que sur un contrôle strict, déterministe et descendant du système.

9 Conclusion

Ce travail ne prétend pas apporter une solution magique ou complète au problème de l'alignement. Il propose avant tout une hypothèse conceptuelle forte : le non-alignement chronique est une conséquence inévitable des architectures actuelles fondées uniquement sur la maximisation statistique d'objectifs explicites.

Ainsi, plutôt que d'ajouter continuellement des couches superficielles de contrôle et de filtrage à des systèmes toujours plus puissants (une approche qui s'apparente à colmater les brèches d'un barrage fissuré) il devient nécessaire de repenser plus profondément la nature même de l'apprentissage artificiel.

L'approche proposée suggère qu'une compréhension implicite du monde ne peut pas être programmée directement par l'homme, mais doit être vécue, s'extrayant d'une expérience continue au sein d'un écosystème complexe. Dans cette perspective, l'avenir de l'alignement ne reposera plus sur des fonctions mathématiques de récompense artificielles, mais sur notre capacité à guider les conditions d'émergence d'une intelligence dont le cadre de compréhension du monde sera harmonieusement aligné avec le vivant.